

# 基于关键信息增强的中文长文本摘要自动生成

李永星<sup>1</sup> 黄文明<sup>1</sup> 肖雁南<sup>1</sup> 温雅媛<sup>2</sup> 邓珍荣<sup>1</sup>

(1. 桂林电子科技大学计算机与信息安全学院 桂林 541004)(2. 广西师范大学电子工程学院 桂林 541004)

**摘 要** 现有的文本自动摘要方法在处理长文本过程中存在关键信息冗余、准确率低的问题。论文提出一种面向中文长文本的三阶段文本摘要算法,首先利用文本压缩算法对长文本进行固定范围的信息压缩,过滤与主题无关的冗余信息,然后结合预训练模型 Bert 学习句子深层语义特征,进一步提取主题信息丰富的关键句,最后使用融合指针机制的 Seq2Seq 模型对关键句进行生成式重写。通过基于真实大规模财经领域长文本数据上的实验,验证了该算法在中文长文本摘要上的有效性。

**关键词** 摘要生成;长文本压缩;预训练;摘要生成;指针机制

**中图分类号** TP391 **DOI**:10.3969/j.issn.1672-9722.2024.11.031

## Automatic Summarization of Chinese Long Text Based on Key Information Enhancement

LI Yongxing<sup>1</sup> HUANG Wenming<sup>1</sup> XIAO Yannan<sup>1</sup> WEN Yayuan<sup>2</sup> DENG Zhenrong<sup>1</sup>

(1. School of Computer and Information Security, Guilin University of Electronic Technology, Guilin 541004)

(2. College of Electronic Engineering, Guangxi Normal University, Guilin 541004)

**Abstract** The existing automatic text summarization methods have the problems of redundant key information and low accuracy in processing long texts. This paper proposes a three-stage text summarization algorithm for Chinese long text. Firstly, the text compression algorithm is used to compress the long text information in a fixed range, and the redundant information irrelevant to the topic is filtered. Then, the deep semantic features of sentences are learned by combining the pre-training model Bert, and the key sentences with rich topic information are further extracted. Finally, the Seq2Seq model with the pointer mechanism is used to rewrite the key sentences. The effectiveness of this algorithm on Chinese long text summarization is verified by experiments based on real large-scale long text data in financial field.

**Key Words** text summarization, long text compression, pre-training, summary generation, pointer mechanism

**Class Number** TP391

## 1 引言

信息时代虽然给我们带来了便利,但也给用户造成了不小的负担,比如信息冗余、信息过载等,如何快速、精确地从海量数据中获取主要信息成为当前亟待解决的问题。自动文本摘要利用机器对输

入内容进行压缩提炼,输出包含关键信息的简短摘要,已成为自然语言处理中的一项重要技术。

当前,自动文本摘要技术按照摘要生成的方法大致分为两类——抽取式摘要生成方法和生成式摘要生成方法。抽取式方法的实质是对文本中的句子进行计算评分,选取得分较高的句子作为关键

\* 收稿日期:2024年5月13日,修回日期:2024年6月18日

**基金项目**:广西科技厅广西重点研发计划(编号:桂科AB20238013);广西图像图形智能处理重点实验室研究课题(编号:GIIP2011)资助。

**作者简介**:李永星,男,硕士研究生,研究方向:自然语言处理。黄文明,男,教授,研究方向:自然语言处理、图形图像处理。肖雁南,男,硕士,研究方向:大数据处理、人工智能。温雅媛,女,硕士,研究方向:大数据分析。邓珍荣,女,研究员,研究方向:文本生成、对话生成、自然语言处理。

句形成摘要。例如, Moratanch等<sup>[1]</sup>根据句子的统计和语言特征,从原始手稿中选择重要的句子和段落等串联成较短的摘要。张其文等<sup>[2]</sup>利用文本聚类技术对句子进行聚类实现信息合并,从每类中抽取代表句生成摘要主题。虽然抽取式方法能保留原文大部分的关键信息,但生成的摘要存在连贯性差、语义单一、重复度高、内容不够精简等问题。

生成式方法则是通过自然语言理解技术对原文进行语义层面的分析,对重要的信息进行捕捉和学习,并利用文本生成技术形成摘要。如Rush<sup>[3]</sup>等利用端到端模型进行摘要生成。Zhang<sup>[4]</sup>等采用双向循环神经网络代替单向循环神经网络,提高了摘要生成的准确率。但生成式摘要方法在长文本上存在一定的局限性,因为随着文本输入序列长度的增加,模型无法准确获取文本的全局信息,导致生成的摘要不够精确。

针对上述问题,本文从增强模型对文本关键信息提取能力的角度出发,提出一种结合抽取式和生成式方法的三阶段摘要生成模型,先通过长文本压缩算法过滤与主题无关的冗余信息,有效缩小原始文本的长度,然后利用基于预训练方法BERT<sup>[5]</sup>的关键句抽取模型充分提取文本语义特征,获取与主题贴合度较高的句子,最后在seq2seq基础架构上设计自动摘要生成模型,对关键句进行生成式重写。

## 2 相关工作

### 2.1 预训练模型

预训练模型的主要思路是利用海量的无标签数据训练得到一个语言模型,在下游任务中使用模型的参数进行初始化并进行微调,以达到改善具体任务性能的效果。如基于深度上下文表示的ELMO模型<sup>[6]</sup>,根据上下文来动态确定词向量。语言预测模型GPT<sup>[7]</sup>将预训练任务与具体下游任务进行联合训练。基于深度双向Transformer<sup>[8]</sup>的预训练模型BERT设计了语言遮蔽模型和下一句预测机制两个预训练任务,使得模型通用性更强。

### 2.2 编码器-解码器框架

Seq2Seq框架<sup>[9]</sup>可以解决输入序列与输出序列长度不相同的问题,自动摘要生成正是这类任务。Seq2Seq模型是一个Encoder-Decoder结构的网络,Encoder的任务是将输入序列编码成一个定长的语义向量C,Decoder的任务是对语义向量C进行解码并转化为输出序列。Seq2Seq的具体工作流程如图1所示。



图1 序列到序列模型

## 3 基于关键信息增强的中文长文本摘要生成方法

本文提出的摘要生成模型包含长文本压缩、关键句抽取和摘要生成三个阶段。在长文本压缩阶段,提出基于图模型的长文本压缩算法TRMMR(TextRank with Maximal Marginal Relevance),对长文本中的句子进行排序筛选,过滤掉与文章主题贴合度较低的句子,有效缩短源文本长度。在关键句抽取阶段,使用基于Bert的关键句抽取模型充分提取文本语义特征,进一步抽取包含主题信息的关键句。在摘要生成阶段,利用端到端的摘要生成模型对关键句进行重写,获得最终摘要。模型具体框架如图2所示。




图2 三阶段文本摘要模型

### 3.1 基于图模型的长文本压缩算法

针对长文本中冗余信息过多导致生成摘要质量不佳的问题,本文提出一种长文本压缩算法TRMMR,结合改进的图模型算法与句子的浅层特征,实现文本“降噪”的同时缩短文本长度。首先根据本文所定义的特征计算公式,分别求出句子的位置特征和关键词特征得分。然后利用Doc2Vec<sup>[10]</sup>算法将句子转换为句向量,并将句向量间的余弦相似度用作TextRank<sup>[11]</sup>中的边值计算方法,在整个图模型中进行迭代运算。最后综合各项指标进行组

合加权,即可得出每个句子的最终分数。具体计算公式如下:

$$Score_{S_i} = \alpha \cdot TextRank_{S_i} + \beta \cdot Pos_{S_i} + \gamma \cdot Keyword_{S_i} \quad (1)$$

$$TextRank_{S_i} = (1-d) + d \cdot \sum_{V_j \in In(V_i)} \frac{w_{ji}}{\sum_{V_k \in Out(V_j)} w_{jk}} W(V_j) \quad (2)$$

$$Pos_{S_i} = k \cdot (x - \frac{n}{2}) \quad (3)$$

$$Kw(S_i) = \frac{c_i}{N} \quad (4)$$

其中,  $\alpha$ 、 $\beta$ 、 $\gamma$  分别代表 TextRank 得分、位置特征得分、关键词特征得分所占的比例。在 TextRank 计算中,  $V_i$  代表图中任一节点,  $In(V_i)$  和  $Out(V_j)$  分别表示指向顶点  $V_i$  和  $V_j$  指向的顶点集合,  $d$  代表阻尼系数,  $w_{ji}$  代表顶点  $V_i$  和  $V_j$  的连接权重。在位置得分计算中,  $x$  代表句子位置,  $n$  为全文句子总数。在关键词特征计算中,  $c_i$  代表句子包含的关键词个数,  $N$  为全文关键词总数。为了保证候选句的多样性,使得短文本包含的信息更加全面,本文将 MMR 算法应用到句子抽取中,具体公式如下:

$$TRMMR = Arg \max_{D_i \in R \setminus S} [\lambda \cdot S_{D_i} - (1-\lambda)(\max_{D_j \in S} Sim(D_i, D_j))] \quad (5)$$

其中,  $S_{D_i}$  代表句子  $D_i$  的重要性得分,  $R$  代表原文句子集合,  $S$  代表已抽取的候选句集合,  $Sim(D_i, D_j)$  代表句子  $D_i$  和  $D_j$  基于 Dov2Vec 向量表示的余弦相似度,  $\lambda$  为调节参数。若想句子的 TRMMR 值越高,则该句的特征得分应该越大,而负号之后的计算部分应该越小,即均衡考虑了候选句的重要性与信息冗余度。利用 TRMMR 算法进行

候选句抽取的整体步骤如下:

1) 利用改进的 TextRank 图模型计算每个句子得分,并存放至集合  $R$  中,取得分最高的句子  $X_i$  加入到集合  $S$  中。

2) 计算集合差  $R \setminus S$  中待抽取句子与  $X_i$  之间的分数,将计算得到的 TRMMR 值从大到小进行排序,选择排在第一位的句子  $X_j$ ,添加到集合  $S$  中。

3) 将  $R \setminus S$  集合中每个句子在步骤 2) 中计算得到的 TRMMR 值作为其新的得分  $S_{D_i}$ ,然后计算它们与  $X_j$  的关系,挑选最优的句子添加到集合  $S$  中。

4) 重复步骤 3),直到集合  $S$  中抽取的候选句数达到数量  $K$ ,并组成候选句集。

### 3.2 关键句抽取模型

尽管 TRMMR 算法能有效过滤长文本中的噪音,但对于文本的关键信息挖掘能力欠佳,且一部分精简后的长文本篇幅较长,导致生成式摘要模型无法收敛。为此,本文引入 BERT 模型来增强模型对关键信息的抽取能力。为了使 BERT 更适用于句子级任务,本文对其做了部分修改,如图 3 所示。

为了更好地表示单个句子,引入句标记、段落标记、位置标记三种表征来初始化句向量。句标记包括首部标记[CLS]和尾部标记[SEP],段落标记是指根据句子序号的奇偶性嵌入标记  $E_A$  或  $E_B$ ,位置标记是指按照句子在文本中的排序依次嵌入标记。

Bert 使用 Transformer Encoder 作为编码器,其中 Encoder 由  $N$  个编码层叠加而成,每个编码层由多头注意力(Multi-Head Attention)子层和前馈神经网络子层组成,每两个子层之间使用残差连接,

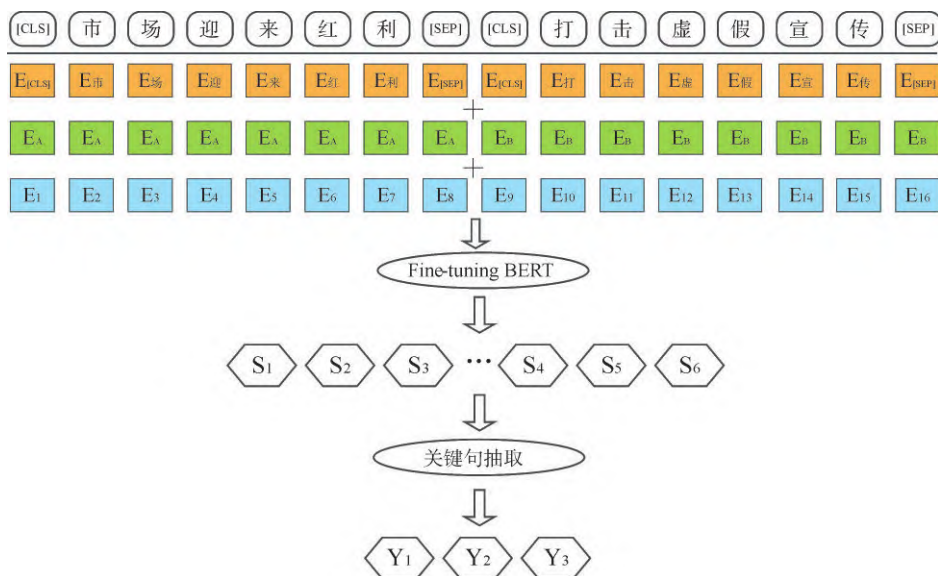


图3 基于BERT的关键句抽取模型



最后再接一个层归一化。

Multi-Head Attention 通过将输入文本特征映射到不同的特征空间,以达到提取不同语义特征的效果。Multi-Head Attention 机制由  $h$  个不同的 Self-attention 集成, Self-attention 计算公式如下:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (6)$$

其中,  $Q$ 、 $K$ 、 $V$  分别代表 query 向量、key 向量、value 向量,由输入向量  $X$  乘以 3 个不同的权值矩阵  $W^Q$ 、 $W^K$ 、 $W^V$  得到。

则 Multi-Head Attention 的计算公式为

$$Z = \text{MultiHead}(Q, K, V) = \text{Concat}(Z_1, \dots, Z_i)W^O \quad (7)$$

$$Z_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (8)$$

最后,将  $Z$  输入到 Encoder 的下一个子层,则第  $l$  层的编码层的计算公式如下:

$$\tilde{h}^l = \text{LN}(\text{MultiHead}(Q^l, K^l, V^l) + Q^l) \quad (9)$$

$$h^l = \text{LN}(\text{FFN}(\tilde{h}^l) + \tilde{h}^l) \quad (10)$$

$$\text{FFN}(\tilde{h}^l) = (\text{ReLU}(\tilde{h}^l w_1^l) w_2^l + b^l) \quad (11)$$

其中,  $\tilde{h}^l$  代表第  $l$  层 Encoder 的输入,  $\text{LN}(\cdot)$  代表归一化操作,  $\text{FFN}$  代表前馈网络子层,  $w_1^l$ 、 $w_2^l$ 、 $b^l$  为模型的训练参数,最后得到第  $L$  层 Encoder 的输出  $h^L$ 。

经过 Bert 模型预训练层后得到与上下文相关的句向量  $S = [s_1, s_2, \dots, s_n]$ , 利用其包含的文档级特征来筛选主题贴合度较高的关键句,即在抽取模型的输出层通过一个 sigmoid 激活函数,对于第  $L$  层 Encoder 的输出向量  $h^L$ ,提取句子得到的概率作为预测分数,计算公式如下:

$$y_i = \sigma(h_i^L \times w + b) \quad (12)$$

通过抽取模型得到每个句子的分数后,按照分数从高到低的顺序对句子进行排序,取分数排名前三的句子作为关键句,进一步精简源文本的信息。

### 3.3 基于 Seq2Seq 的摘要生成模型

经过关键句抽取模型得到的关键句集合字数较多且连贯性较差,而实际人工摘要长度一般都比较简短,因此我们需要构建端到端的摘要生成模型来对关键句进行重写,生成更加简洁、连贯的摘要。

Transformer 有效解决了 CNN、RNN 等传统模型存在的长距离依赖和并行计算的问题,因此本文使用 Transformer 作为 Seq2Seq 的基础模型。Transformer 的 Encoder 已经在上文介绍过,而 Decoder 与 Encoder 的流程类似,主要不同是 Decoder 在

Multi-Head Attention 中做了两方面改动,一方面是加入了 Mask 操作,使得输入的序列  $Y = \{y_1, y_2, \dots, y_m\}$  中的  $y_t$  只能观测到前  $t-1$  个词,无法观测到它之后的词,从而实现自回归模型。另一方面是加入了一个 Encoder-Decoder Attention 层,以实现与 Encoder 的信息交互。

在 Encoder-Decoder 模型生成摘要时, Decoder 端只能从固定的词汇表中选择词语,生成的摘要容易出现 OOV 问题。为此,本文在 Decoder 端融入了指针生成机制<sup>[12]</sup>,即在解码器的最后阶段,指针生成网络会产生两个概率,分别为  $p_{gen}$  和  $1 - p_{gen}$ 。第  $t$  时间步的  $p_{gen}$  由当前 Encoder 输入的上下问向量  $Z_t^e$ , Decoder 当前状态  $h_t^d$  和当前输入  $E_{y_{t-1}}$  得到,计算公式如下:

$$p_{gen_t} = \sigma(W_Z Z_t^e + W_h h_t^d + W_E E_{y_{t-1}}) \quad (13)$$

其中,  $\sigma(\cdot)$  代表 sigmoid 激活函数,  $Z_t^e$  代表编码器第  $t$  时间步的输入上下文向量,  $h_t^d$  代表解码器第  $t$  时间步的隐藏状态,  $E_{y_{t-1}}$  代表第  $t-1$  时间步的词向量。

最后,根据  $p_{gen}$  和  $p_{voc}$  以及注意力分布,得到生成词汇的概率分布  $p(w)$ ,计算公式如下:

$$p(w) = p_{gen} * p_{voc}(w) + (1 - p_{gen}) * \alpha_t \quad (14)$$

其中,  $p_{voc}(w)$  代表目标词  $w$  在词表中的概率分布,  $\alpha_t$  表示生成的词向量对编码器的输出的注意力分布。

## 4 实验

### 4.1 数据集构建

本文通过网络爬虫对新浪财经新闻进行收集,过滤掉正文长度  $L$  过短 ( $L < 500$ ) 的样本,最终得到大小约为 1.1 G 的中文长文本数据集。

表1 文本数据样例

参考摘要	京东零售调整战略布局:开放式货架转向全零售形态
正文	当今社会,零售场景与生活场景之间不再有明显的界线,购物行为变得越来越可以发生在任何地方,如何在多种场景和业态下满足消费者的每一个需求,成为零售企业的必修课。……(2 769字)

### 4.2 评价方法

ROUGE<sup>[13]</sup>作为摘要生成任务主流的评价指标,其中使用最多的是 ROUGE-N, ROUGE-N 的值越大,表明预测摘要与标准摘要的相似度越高。除

此外,本文还引入 ROUGE-L 评价指标,它的特点是不要求词语连续匹配,只按照词的出现顺序来匹配最长公共子序列。

### 4.3 实验结果与分析

本文构建的中文长文本数据集上,将提出的摘要生成模型与目前表现良好的模型进行对比实验,实验结果如表 2 所示。

表 2 模型结果对比

Model	ROUGE-1	ROUGE-2	ROUGE-L
Pgn+coverage	38.7	24.4	36.5
SummaRunner <sup>[14]</sup>	39.8	25.5	37.2
NeuSum <sup>[15]</sup>	40.5	26.1	38.5
GE <sup>[16]</sup>	41.9	28.3	39.2
Ours	43.1	29.7	40.2

通过表 2 的实验结果对比可以看出,本文提出的方法针对长文本摘要任务表现出较好的处理能力,在 ROUGE-1、ROUGE-2 和 ROUGE-L 评测中本文模型都超过了所有对比实验模型。表 3 展示了本文模型和其他模型生成的摘要对比,从例子中可以看出 SummaRunner 生成的摘要缺少对原文主旨信息的概括,NeuSum 生成的摘要存在信息冗余的问题。PGN 模型虽然生成了简短的摘要,但是与主题的贴合度较差,GE 生成的摘要太过简洁,缺失部分重要信息。本文模型先通过 TRMMR 算法缩短了文本长度并保留了全文的关键信息,再由基于预训练的抽取模型进行信息增强,因此生成的摘要还包括“商业模式”这样的关键字,有效地提高了长文本摘要生成的质量和可读性。

表 3 模型输出与参考摘要对比

参考摘要	京东零售调整战略布局:开放式货架转向全零售形态
SummaRunner	2月26日,京东零售子集团CEO徐雷在京东零售子集团3C电子及消费品零售事业群消费品事业部合作伙伴大会公布了零售子集团最新战略布局。
NeuSum	“随着互联网的发展,购物行为可以发生在任何地方,这是京东零售子集团向全零售形态转变的最重要原因。”徐雷认为,这标志着京东零售子集团在商业模式上将迎来巨大变化:从开放式货架向全零售形态转变。
Pgn+coverage	京东零售集团在多种场景下变化了商品服务模式。
GE	京东公布了零售子集团的最新战略布局。
Ours	京东零售商业模式将从开放式货架向全零售形态转变。

为进一步验证 TRMMR 算法对长文本信息的降噪能力和基于 Bert 的句子抽取模型对关键信息的增强效果,本文对三阶段摘要生成模型进行消融分析,实验结果如表 4 所示,其中 T 代表单独的生成式摘要模型 Transformer。

表 4 消融实验结果

Model	ROUGE-1	ROUGE-2	ROUGE-L
T	42.0	28.8	39.4
Bert+T	42.5	29.2	39.9
TRMMR+Bert+T	43.1	29.7	40.2

由表 4 可知,两阶段生成式模型在 ROUGE 得分上均高于单独的生成式模型,此改进验证了关键句抽取模块在长文本摘要生成中存在的必要性。三阶段生成式模型 ROUGE-1、ROUGE-2、ROUGE-3 的得分在两阶段摘要模型基础上提高了 0.6%、0.7%、0.3%,此改进也验证了基于 TRMMR 的长文本压缩模块和关键句抽取模块存在的必要性。综上所述,文本压缩和关键句抽取这两个模块在针对长文本的摘要生成任务中能够起到重要作用。

## 5 结语

针对长文本数据给自动摘要任务带来的困难与挑战,本文提出了一种基于关键信息增强的三阶段长文本摘要生成方法,包括长文本压缩、关键句抽取和摘要生成三个阶段。该方法充分结合抽取式和生成式摘要方法以及预训练模型的各自优势,有效提升在处理长文本时的摘要效果。在真实财经新闻领域的数据上,实验对比分析了以往表现较好的摘要模型,本文方法在准确性上达到了最好的效果。下一步,将对 Transformer 模型进行改进和优化,使其能够更好地应用到端到端的任务中。

### 参考文献

- [1] Moratanch N, Chitrakala S. A survey on extractive text summarization [C]//2017 International Conference on Computer, Communication and Signal Processing, 2017: 1-6.
- [2] ZHANG Qiwen, LI Ming. Study and implementation of approach to automatic extraction of text topic [J]. Computer Engineering and Design, 2006, 27 (15): 2744-2746, 2766.
- [3] Rush A M, Chopra S, Weston J. A neural attention model for sentence summarization [C]//Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 2015: 379-389.

- [4] Jiajun Z, Long Z, Yang Z, et al. Synchronous Bidirectional Inference for Neural Sequence Generation [J]. ArXiv Preprint ArXiv: 1902.08955, 2019.
- [5] Devlin J, Chang Mingwei, Lee K, et al. BERT: pre-training of deep bidirectional transformers for language understanding [C]//Proceedings of Conference of the North American Chapter of the Association for Computational Linguistics, 2019: 4171–4186.
- [6] Peters M E, Neumann M, Iyyer M, et al. Deep contextualized word representations [C]//Proceedings of Conference of the North American Chapter of the Association for Computational Linguistics, 2018: 2227–2237.
- [7] Radford A, Narasimhan K, Salimans T, et al. Improving language understanding with unsupervised learning [R]. 2018.
- [8] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [C]//Advances in Neural Information Processing Systems, 2017: 5998–6008.
- [9] Nallapati R, Zhou B, Dos Santos C, et al. Abstractive text summarization using sequence-to-sequence rnns and beyond [C]//Proceedings of The 20th SIGNLL Conference on Computational Natural Language Learning, 2016: 280–290.
- [10] Mikolov T, Sutskever I, Chen K, et al. Distributed representations of words and phrases and their compositionality [C]//Advances in Neural Information Processing Systems., 2013: 3111–3119.
- [11] Chen N, Litvak N, Olvera-Cravioto M. Generalized PageRank on directed configuration networks [J]. Random Structures & Algorithms, 2017, 51(2): 237–274.
- [12] See A, Liu P J, Manning C D. Get to the point: Summarization with pointer-generator networks [C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, 2017: 1073–1083.
- [13] Lin C Y, Hovy E. Manual and automatic evaluation of summaries [C]//Proceedings of the ACL-02 Workshop on Automatic Summarization, 2002: 45–51.
- [14] Nallapati R, Zhai F, Zhou B. Summarunner: A recurrent neural network based sequence model for extractive summarization of documents [C]//Proceedings of the 31st AAAI Conference on Artificial Intelligence, 2017: 3075–3081.
- [15] Zhou Q, Yang N, Wei F, et al. Neural document summarization by jointly learning to score and select sentences [J]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, 2018: 654–663.
- [16] Lin J, Sun X, Ma S, et al. Global encoding for abstractive summarization [C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, 2018: 163–169.

(上接第 3302 页)

- [10] DENG W, LIANG Z, KANG G, et al. Image-Image Domain Adaptation with Preserved Self-Similarity and Domain-Dissimilarity for Person Re-identification [J]. IEEE, 2017.
- [11] FU Y, WEI Y, WANG G, et al. Self-similarity Grouping: A Simple Unsupervised Cross Domain Adaptation Approach for Person Re-identification [J]. IEEE, 2018.
- [12] GE Y, CHEN D, ZHU F, et al. Self-paced Contrastive Learning with Hybrid Memory for Domain Adaptive Object Re-ID [J]. ArXiv, 2020.
- [13] HEHE FAN L Z, CHENGGANG Y AN, AND YI YANG. Unsupervised person re-identification: Clustering and finetuning [J]. ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM) 2018; 14(4):1–8.
- [14] LIN Y, DONG X, ZHENG L, et al. A Bottom-Up Clustering Approach to Unsupervised Person Re-Identification [C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33: 8738–45.
- [15] WANG D, ZHANG S. Unsupervised Person Re-identification via Multi-label Classification [J]. IEEE, 2020.
- [16] HE K, FAN H, WU Y, et al. Momentum Contrast for Unsupervised Visual Representation Learning [J]. IEEE, 2019.
- [17] DAI Z, WANG G, YUAN W, et al. Cluster Contrast for Unsupervised Person Re-Identification [J]. IEEE, 2021.